Assignment 4

Table of contents

restatapi	2
Toc. eurostat	2
GDP NUTS 3	2
Population demo_r_pjanaggr3	4
Oppgave 1	4
Oppgave 2	4
Oppgave 3	5
Oppgave 4	5
Oppgave 5	5
Oppgave 6	5
Oppgave 7	6
Oppgave 8	6
Oppgave 9	6
Oppgave 10	7
Oppgave 11	7
Oppgave 12	7
Oppgave 13	8
Oppgave 14	9
Oppgave 15	9
Oppgave 16	9
Oppgave 17	10
Oppgave 18	11
Oppgave 19	12
Oppgave 20	12
Oppgave 21	12
Oppgave 22	12
	12
Oppgave 24	13
	15

Oppgave 26																				16
Oppgave 27																				17
Oppgave 28																				17
Oppgave 30																				19
Oppgave 31																				20
Oppgave 32																				22
Oppgave 33																				22
Oppgave 34																				23
Oppgave 35																				24
Oppgave 36																				24
Oppgave 37																				24
Oppgave 38																				24
Oppgave 39																				25
Oppgave 40																				25
Oppgave 41																				25
Oppgave 42																				25
Oppgave 43																				26
Oppgave 44																				26

restatapi

Toc. eurostat

Vi starter med å hente innholsfortegnelsen fra eurostat. Vi henter innholdsfortegnelsen i rent tekst format. Innholdsfortegnelsen gir vi navnet toc_txt.

GDP NUTS 3

Vi søker i toc_txt etter tabeller med GDP på nivå NUTS 3 vha. funksjonen str_detect(). Denne funksjonen skiller mellom store og små bokstaver. Siden vi ikke vet hvilken skrivemåte som er brukt for gdp og NUTS 3 benytter vi regex for å matche både små og store bokstaver. Vi benytter filter() for å finne de tabellene vi ønsker. Vi benytter select() for å velge ut kolonnene title og code som vi ønsker å se på. Vi benytter flextable() for å vise tabellen. Vi benytter til slutt autofit() for å tilpasse tabellen til siden. Detaljer om regex finner dere i Slides: Strings and regular expressions og i r4ds ed. 1 chp. 14.

Vi ønsker å finne tabellbeskrivelser som både inneholder gdp og nuts 3. Trikset for enkelt å få dette til er å ha AND (&) utenfor str_detect(). Det går an å få til en AND inne i en regexp, men dette kan fort bli kronglete og komplisert.

Vi finner fire tabeller listet i toc_txt.

title	code
Average annual population to calculate regional GD data (thousand persons) by NUTS 3 regions	P nama_10r_3popgdp
Gross domestic product (GDP) at current market prices by NUTS 3 regions	nama_10r_3gdp
European Union trade mark (EUTM) applications per billion GDP by NUTS 3 regions	ipr_ta_gdpr
Community design (CD) applications per billion GDP by NUTS 3 regions	ipr_da_gdpr

Vi velger å benytte tabellen med kode nama_10r_3gdp som har forklarende tekst «Gross domestic product (GDP) at current market prices by NUTS 3 regions». Vi henter «Data Structure Definition» for å finne hva som finnes i dette datasettet. Informasjonen benyttes for å definer «filters» for spørringen mot eurostat.

MERK! Merk bruken av nuts_level = "3" i filters for å få data på NUTS 3 nivå. Denne parameteren var ikke så lett å finne.

Vi laster så ned «Data Structure Definition (DSD)» for tabellen med code nama_10r_3gdp.

concept	code	name
freq	A	Annual
unit	MIO_EUR	Million euro
unit	EUR_HAB	Euro per inhabitant
unit	EUR_HAB_	Euro per inhabitant in percentage of the EU27 (from 2020) average
unit	MIO_NAC	Million units of national currency
unit	MIO_PPS_E	Million purchasing power standards (PPS, EU27 2020 from 2020)
unit	PPS_EU27_	Purchasing power standard (PPS, EU27 from 2020), 2020 HAB per inhabitant
unit	PPS_HAB_I	Purchasing power standard (PPS, EU27 from 2020), EU27_i2020itant in percentage of the EU27 (from 2020) average
geo	EU27_2020	European Union - 27 countries (from 2020)

concept	code	name
geo	BE	Belgium
geo	BE1	Région de Bruxelles-Capitale/Brussels Hoofdstedelijk Gewest
geo	BE10	Région de Bruxelles-Capitale/Brussels Hoofdstedelijk Gewest
geo	BE100	Arr. de Bruxelles-Capitale/Arr. Brussel-Hoofdstad
geo	BE2	Vlaams Gewest
geo	BE21	Prov. Antwerpen

Utfra kodene i dsd_gdpkan vi da formulere følgende spørring mot Eurostat:

Vi velger å benytte MIO_PPS_EU27_2020 som mål på GNP. Dette er GNP i løpende priser (million Euro). Det kunne vært aktuelt å benytte PPS_EU27_2020_HAB som skal være GNP målt i konstant kjøpekraft. Det synes imidlertid som om PPS_EU27_2020_HAB har urimelige/åpenbart feil verdier for en del regioner.

Population demo_r_pjanaggr3

Oppgave 1

Søk i toc_txt for tabeller med population og NUTS 3. Pass på at dere dekker både population og Population og ulike skrivemåter for NUTS 3.

Oppgave 2

- i. Finn koden for tabellen med forklarende tekst «Average annual population to calculate regional GDP data (thousand persons) by NUTS 3 regions».
- ii. Last ned Data Structure Definition (DSD) for denne tabellen.
- iii. Bruk opplysningene i DSD for å formulere en spørring mot Eurostat og last ned dataene. Gi dataene lastet ned samme navn som Eurostat sin kode for tabellen. Vi er bare interessert i totalbefolkning og ignorerer derfor både kjønn og alder. Vi ønsker data for årene 2000-2020.
- iv. Bruk filter(str_length(geo) == 5) for å begrense datasettet til NUTS3 regioner. Vi vil gjøre vår egen aggregering.
- v. Hent data for landene:

Hent ned befolkningsdata fra tabellen som har teksten «Population on 1 January by broad age group, sex and NUTS 3 region». Gi også her dataene samme navn som tabell-koden hos Eurostat. Igjen vil vi ikke skille på kjønn eller alder.

Oppgave 4

Bruk setdiff() for å finne NUTS3 soner som inngår i «Average annual population to calculate regional GDP data (thousand persons) by NUTS 3 regions», men ikke i «Population on 1 January by broad age group, sex and NUTS 3 region».

```
[1] "DKZZZ" "ESZZZ" "ITG2D" "ITG2E" "ITG2F" "ITG2G" "ITG2H" "ITZZZ" "NLZZZ" [10] "ND020" "ND074" "ND081" "ND082" "ND091" "ND092" "ND0A1" "ND0A2" "ND0A3" [19] "ND0B2" "NDZZZ"
```

Oppgave 5

Bruk setdiff() for å finne NUTS3 soner som inngår i «Population on 1 January by broad age group, sex and NUTS 3 region», men ikke i «Average annual population to calculate regional GDP data (thousand persons) by NUTS 3 regions».

```
[1] "BE221" "BE222" "BE321" "BE322" "BE324" "BE325" "BE326" "BE327" "FRXXX" [10] "ITG25" "ITG26" "ITG27" "ITG28" "ITG29" "ITG2A" "ITG2B" "ITG2C" "N0011" [19] "N0012" "N0021" "N0022" "N0031" "N0032" "N0033" "N0034" "N0041" "N0042" [28] "N0043" "N0051" "N0052" "N0053" "N0061" "N0062" "N0073"
```

Oppgave 6

Gjør en full_join() av de to populasjonstabellene. Gi resultatet navnet full_pop_nuts3.

Et alternativ som kanskje er mer «clean», er å plukke ut de variablene vi trenger før full_join().

Bruk setdiff() for å sjekke sonene i full_pop_nuts3 mot dem vi har i GDP tabellen.

```
[1] "BE221" "BE222" "BE321" "BE322" "BE324" "BE325" "BE326" "BE327" "FRXXX" [10] "ITG25" "ITG26" "ITG27" "ITG28" "ITG29" "ITG2A" "ITG2B" "ITG2C" "N0011" [19] "N0012" "N0021" "N0022" "N0031" "N0032" "N0033" "N0034" "N0041" "N0042" [28] "N0043" "N0051" "N0052" "N0053" "N0061" "N0062" "N0073"
```

Oppgave 8

Bruk setdiff() for å sjekke sonene i GDP tabellen mot dem vi har i full_pop_nuts3.

```
[1] "ATZZZ" "BEZZZ" "FIZZZ" "FRZZZ" "PTZZZ" "SEZZZ"
```

Oppgave 9

Fjern **ZZZ sonene fra nama_10r_3gdp.

```
geo time pop.x pop.y
 1: NO053 2014 261458
2: N0060 2014 441193 443090
3: NO061 2014 306067
4: NO053 2015 263736
5: NO060 2015
                   NA 447910
6: NO061 2015 310093
                          NA
7: NO053 2016 265151
                          NA
8: NO060 2016 449457 452090
9: NO061 2016 313105
10: NO053 2017 266274
11: NO060 2017 454596 457000
12: NO061 2017 317363
                          NA
13: NO053 2018 266858
14: NO060 2018 458742 460170
15: NO061 2018 320884
16: NO053 2019 267420
17: NO060 2019 462032 465910
18: NO053 2020 267642
19: NO060 2020 465136 469910
```

Lag en ny variabel pop i full_pop_nuts3 ut fra diskusjonen ovenfor. Dropp deretter variablene pop.x og pop.y.

Oppgave 11

Undersøk om vi har noen NUTS 3 soner med pop lik 0. Hvis det er noen så rekod disse til NA

Her fant vi at det er 117 hvor antallet er 0

ag_comment: Ok løsning, men mutate_at() er på veg ut. Jeg vil foreslå en enkel ifelse().

Her har vi endret alle 0 verdiene i kollonne pop til NA verdi, så kontrollerer vi at vi ikke har flere 0 verdier

Oppgave 12

Utfør en left_join() der populasjonsdata blir lagt til datasettet som innholder GDP-data. Gi resultatet navnet eu_data.

Her ser vi at vi ikke har likt som i oppgavesettet, men vi finner ikke hvor feilen ligger. Avviket er 123. Vi ser også i oppgave 12 at disse tallene kommer opp som NA verdier.

```
# A tibble: 16 x 2
country Antall
<chr> 1 AT 36
2 BE 45
3 CH 26
```

4	DE	401
5	DK	12
6	EL	52
7	ES	60
8	FΙ	20
9	FR	102
10	ΙE	8
11	IT	108
12	NL	41
13	NO	13
14	${\tt PL}$	73
15	PT	26
16	SE	22

geo	time	gdp	pop
Length: 21282	Length:21282	Min. $:4.539e+07$	Min. : 8400
Class :character	Class :character	1st Qu.:2.906e+09	1st Qu.: 132899
Mode :character	Mode :character	Median :5.293e+09	Median : 241464
		Mean :9.972e+09	Mean : 373445
		3rd Qu.:1.030e+10	3rd Qu.: 441000
		Max. :2.606e+11	Max. :6747068
			NA's :233

country
Length:21282
Class :character
Mode :character

Oppgave 13

Beregn gdp_per_capita for hver NUTS3 region for årene 2000-2020. Avrund til 2 desimaler.

Avrunder til to desimaler.

Sjekker summary gdp_per_capita.

gdp_per_capita
Min. : 3359
1st Qu.: 18277

Median : 23258 Mean : 25291 3rd Qu.: 29392 Max. :177583 NA's :233

Oppgave 14

Bruk case_when() for å legge til variabelen country_name før vi går videre. Østerrike for AT, Belgia for BE etc..

Oppgave 15

Lag de tre variablene NUTS2, NUTS1 og NUTSc fra NUTS3. Dette gjøres enklest vha. mutate() og str_sub(). Bruker også select() for å få variablene i rekkefølgen: country_name, country, year, NUTS3, NUTS2, NUTS1, NUTSc, gdp, pop, gdp_per_capita. NUTSc er vår egen «oppfinnelse» og angir land (to første karakterer i NUTS kode).

Oppgave 16

Bruk koden nedenfor til å beregne Gini-koeffisienter på NUTS2 nivå. Beregn også populasjonen og gdp på NUTS2 nivå. Bruk de to siste for å regne ut gdp_per_capita for hvert NUTS2 område. Finn også antall NUTS3 regioner som finnes i hver NUTS2 region. Gi denne variabelen navnet num_nuts3. Det er viktig at dere beregner Gini-koeffisient før dere aggregerer populasjon og GDP. Resultatet legger dere i en tibble kalt gini_NUTS2.

country_name	country	NUTS2	year
Length:4413	Length:4413	Length:4413	Length:4413
Class :character	Class :character	Class :character	Class :character
Mode :character	Mode :character	Mode :character	Mode :character

pop		go	dp	gdp_per	c_capita	num_nu	ts3
Min. :	0	Min.	:4.539e+07	Min.	: 3359	Min. :	1.000
1st Qu.:	588044	1st Qu	:1.401e+10	1st Qu.	:19725	1st Qu.:	2.000
Median :	1344629	Median	:3.272e+10	Median	:25070	Median :	4.000
Mean :	1781248	Mean	:4.809e+10	Mean	: Inf	Mean :	4.823
3rd Qu.:	2319035	3rd Qu.	.:6.056e+10	3rd Qu.	:32278	3rd Qu.:	6.000

Max. :12291557 Max. :6.996e+11 Max. : Inf Max. :23.000

gini_nuts2
Min. :0.0000
1st Qu.:0.0596
Median :0.1016
Mean :0.1197
3rd Qu.:0.1603
Max. :0.4550
NA's :923

Vi ser at vi har et spenn i Gini-koeffisienten på NUTS2 nivå fra 0.00 til 0.45. Vi har også 800 NAs som stammer fra de 110 NA-ene vi har i pop. Vi ser også at antall NUTS3 i NUTS2 regioner spenner fra 1 til 23.

Sjekker obs. med Gini avrundet til 0,0000.

A tibble: 5 x 8

	country	NUTS2	year	pop	gdp	gdp_per_capita	num_nuts3	gini_nuts2
	<chr></chr>	<chr></chr>	<chr></chr>	<dbl></dbl>	<dbl></dbl>	<dbl></dbl>	<int></int>	<dbl></dbl>
1	AT	AT34	2002	352574	9450050000	26803.	2	0.000358
2	ES	ES43	2001	1059011	12749280000	12039.	2	0.000917
3	ES	ES43	2006	1074937	17609920000	16382.	2	0.000850
4	IT	ITF5	2006	589480	11135870000	18891.	2	0.0000134
5	PL	PL43	2011	1010700	14215740000	14065.	2	0.000745

Oppgave 17

country_name	country	NUTS1	year
Length: 1765	Length: 1765	Length: 1765	Length: 1765
Class :character	Class :character	Class :character	Class :character
Mode :character	Mode :character	Mode :character	Mode :character

pop		go	dp	gdp_per	r_capita	num_r	nuts3
Min. :	0	Min.	:4.539e+07	Min.	: 6423	Min.	: 1.00
1st Qu.:	1722247	1st Qu	.:4.074e+10	1st Qu	.:20511	1st Qu	.: 5.00
Median :	3660852	Median	:8.659e+10	Median	:26424	Median	: 8.00
Mean :	4453624	Mean	:1.202e+11	Mean	: Inf	Mean	:12.06
3rd Qu.:	5866219	3rd Qu	.:1.499e+11	3rd Qu	.:35154	3rd Qu.	:15.00

Max. :18064692 Max. :6.996e+11 Max. : Inf Max. :96.00

gini_nuts1

Min. :0.0205 1st Qu.:0.0841 Median :0.1264 Mean :0.1340 3rd Qu.:0.1681 Max. :0.3912 NA's :364

Oppgave 18

country_name country NUTSc year
Length:312 Length:312 Length:312 Length:312

pop gdp gdp_per_capita num_nuts3 Min. : 3525494 Min. :9.547e+10 Min. : 8859 Min. : 6.00 1st Qu.: 7995331 1st Qu.:2.108e+11 1st Qu.:23525 1st Qu.: 22.00 Median :10558176 Median :3.123e+11 Median :28395 Median : 41.00 Mean :25194380 :6.802e+11 :29173 Mean : 68.21 Mean Mean 3rd Qu.:43474746 3rd Qu.:1.011e+12 3rd Qu.:34344 3rd Qu.: 73.00 :3.147e+12 :61796 Max. :401.00 Max. :83166711 Max. Max.

gini_nutsc

Min. :0.1129 1st Qu.:0.1440 Median :0.1696 Mean :0.1760 3rd Qu.:0.2006

Max. :0.3843

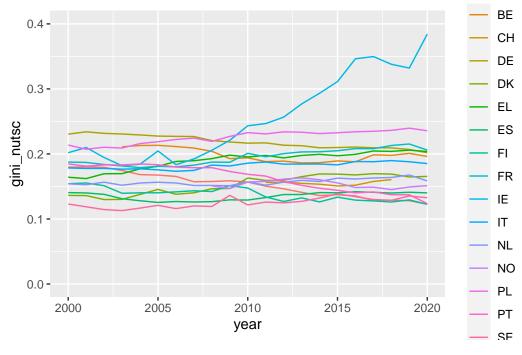
Oppgave 20

Oppgave 21

Oppgave 22

Oppgave 23

Lag et lineplot i g
gplot som viser utviklingen i Gini-koeffisient på nasjonsnivå for de 16
 landene vi har med. Husk argumentet group =.



country_name	gini_nutsc
Irland	0.3842526
Polen	0.2356700
Frankrike	0.2059513
Hellas	0.2037289
Tyskland	0.2019286
Belgia	0.1961939

country_name	gini_nutsc
Italia	0.1852001
Danmark	0.1654875
Nederland	0.1585346
Norge	0.1513034
Spania	0.1401269
Sverige	0.1326921
Portugal	0.1236290
Østerrike	0.1227349
Finland	0.1226160

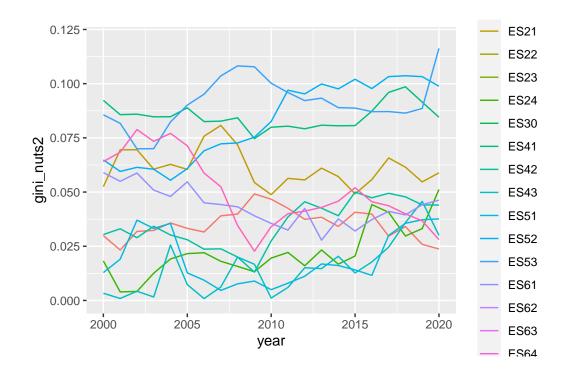
country_name	year	NUTS2	gini_nuts2
Irland	2020	IE04	0.32381271
Irland	2020	IE05	0.38394801
Irland	2020	IE06	0.43667974
Irland	2019	IE04	0.17540553
Irland	2019	IE05	0.27386949
Irland	2019	IE06	0.39881854
Irland	2018	IE04	0.16908587
Irland	2018	IE05	0.33364852
Irland	2018	IE06	0.38049943
Irland	2017	IE04	0.15128465
Irland	2017	IE05	
Irland	2017	IE06	0.37038485
Irland	2016	IE04	0.20793713
Irland	2016	IE05	
Irland	2016	IE06	0.35564750

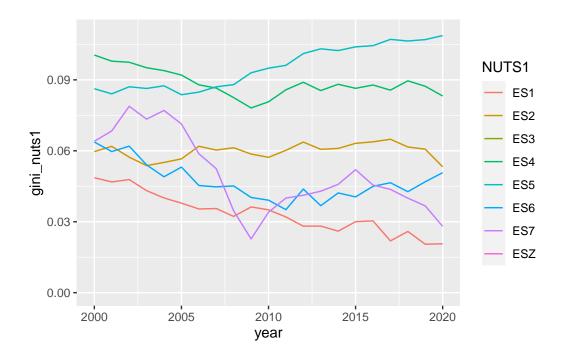
country_name	year	NUTS2	gini_nuts2
Irland	2015	IE04	0.20644955
Irland	2015	IE05	
Irland	2015	IE06	0.33868434
Irland	2014	IE04	0.21429267
Irland	2014	IE05	0.21391715
Irland	2014	IE06	0.39260099
Irland	2013	IE04	0.17296761
Irland	2013	IE05	0.16461776
Irland	2013	IE06	0.38504767
Irland	2012	IE04	0.19374811
Irland	2012	IE05	0.24498225
Irland	2012	IE06	0.35530299
Irland	2011	IE04	0.17174132
Irland	2011	IE05	0.24429047
Irland	2011	IE06	0.34423904
Irland	2010	IE04	0.16571209
Irland	2010	IE05	0.19852714
Irland	2010	IE06	0.32317344
Irland	2009	IE04	0.12750704
Irland	2009	IE05	0.19583203
Irland	2009	IE06	0.26782868
Irland	2008	IE04	0.09187481
Irland	2008	IE05	0.13684591
Irland	2008	IE06	0.26258760
Irland	2007	IE04	0.07999634
Irland	2007	IE05	0.15286464
Irland	2007	IE06	0.23501257

country_name	year	NUTS2	gini_nuts2
Irland	2006	IE04	0.06434473
Irland	2006	IE05	0.15216102
Irland	2006	IE06	0.22348127
Irland	2005	IE04	0.07961666
Irland	2005	IE05	0.15701288
Irland	2005	IE06	0.25673009
Irland	2004	IE04	0.08109590
Irland	2004	IE05	0.14181866
Irland	2004	IE06	0.22757402
Irland	2003	IE04	0.03032893
Irland	2003	IE05	0.15978363
Irland	2003	IE06	0.22778549
Irland	2002	IE04	0.06318606
Irland	2002	IE05	0.23133080
Irland	2002	IE06	0.21019029
Irland	2001	IE04	0.12956185
Irland	2001	IE05	0.17157285
Irland	2001	IE06	0.27125526
Irland	2000	IE04	0.12312552
Irland	2000	IE05	0.14272672
Irland	2000	IE06	0.24578635

Oppgave 25

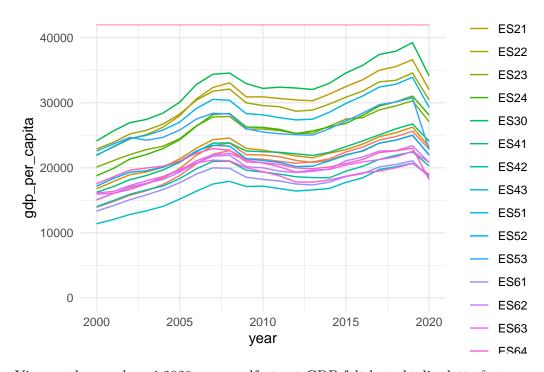
Lag et line-plot som viser utviklingen i Gini-koeffisientene for NUTS2 regionene i Spania.





Det er større fordeling av verdiskapning i NUTS1-regionene enn NUTS2.

Oppgave 28



Vi ser at korona kom i 2020 som medførte at GDP falt betraktelig dette året.

Oppgave 29

Lag et line-plot som viser utviklingen i Gini-koeffisient for NUTS2 regionene i Tyskland.

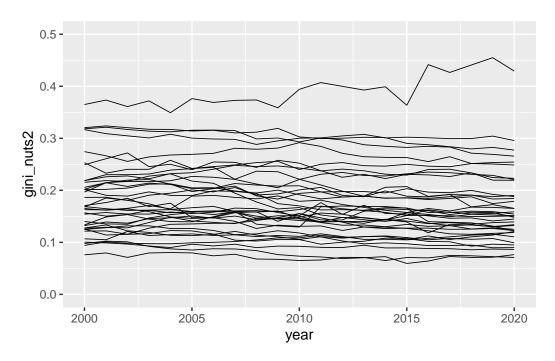
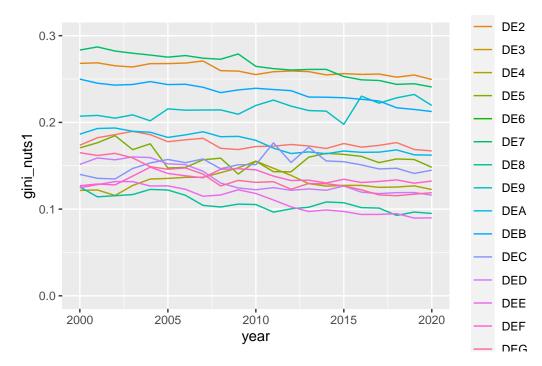
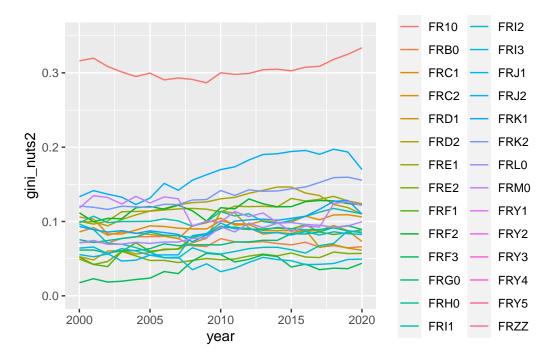


Figure 1: Line-plot som viser utviklingen i Gini-koeffisient for NUTS2 regionene i Tyskland. Det generelle bildet synes å være en svakt synkende tendens, men området med høyest gini har en økende tendens.



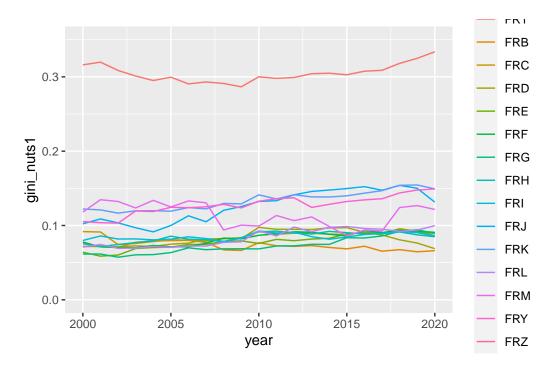
Ikke like mye spredning i NUTS1-regionene.

Oppgave 31



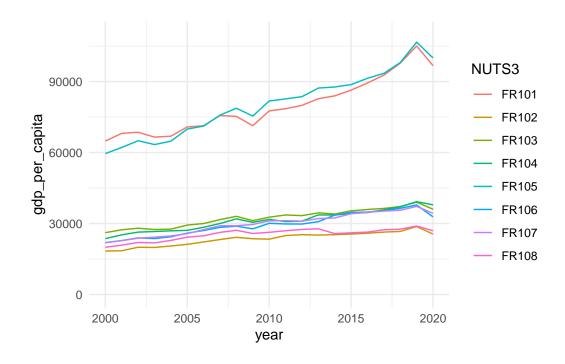
NUTS2	gini_nuts2
FR10	0.33372167
FRJ2	0.16991355
FRK2	0.15555702
FRE1	0.12387708
FRF2	0.12232861
FRM0	0.12162306
FRI1	0.11044726
FRK1	0.11005305
FRD2	0.10996150
FRC1	0.10618012
FRL0	0.09979288
FRG0	0.08927537
FRF1	0.08902390

NUTS2	gini_nuts2
FRI2	0.08564887
FRH0	0.08486201
FRJ1	0.08255820
FRC2	0.07309852
FRB0	0.06609860
FRD1	0.06139475
FRE2	0.05704883
FRI3	0.04934755
FRF3	0.04375468
FRY1	
FRY2	
FRY3	
FRY4	
FRY5	
FRZZ	



Oppgave 33

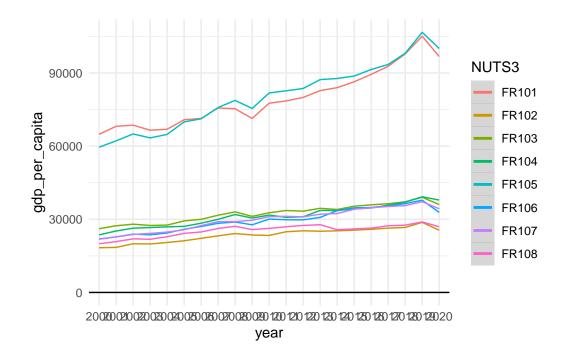
Vi ser at for Frankrike er det en region (FR1) som har klart større forskjeller mht. verdistgning enn de andre. Sjekk denne regionen nærmere.



Oppgave 34

Vis utviklingen i gdp_per_capita for NUTS3 sonene i FR1.

<code>`geom_smooth()`</code> using method = 'loess' and formula = 'y \sim x'



Hva ser ut til å være årsaken til den høye Gini-koeffisienten for FR1?

Det er to soner i NUTS3 som har mer enn dobbel så høy GDP per capita som de resterende. Dette gjør Gini-koeffisienten høy.

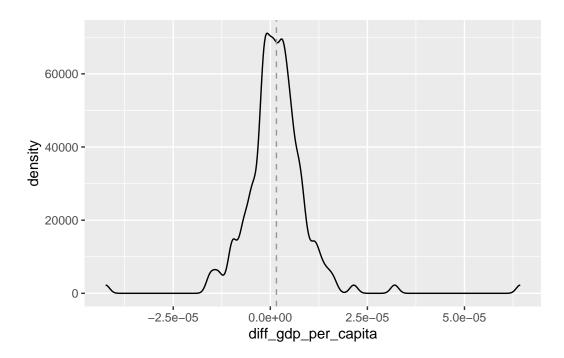
Oppgave 36

Oppgave 37

Oppgave 38

Hent ut koeffisientene fra de 173 modellene og legg resultatet i variabelen mod_coeff. Gjør dette ved å «mappe» funksjonen coeff() på list_column modell. (Hint: Husk at hvis vi ønsker en dataframe så må _df varianten av map.)

Oppgave 40



Oppgave 41

Hvor mange av de 173 regrersjonskoeffisientene for diff_gdp_per_capita er positive?

[1] 105

Oppgave 42

Finn mean av de 173 koeffisientene beregnet for diff_gdp_per_capita.

[1] 1.571215e-06

One Sample t-test

Utfør en enkel t-test for å teste om diff_gdp_per_capita er signifikant større enn 0.

```
data: NUTS2_diff$mod_coeff$diff_gdp_per_capita
t = 2.3441, df = 172, p-value = 0.02022
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
   2.481486e-07 2.894282e-06
sample estimates:
   mean of x
1.571215e-06
```

T-test viser at diff_gdp_per_capita er signifikant større enn 0.

Oppgave 44

Bruk funksjonen plm() fra pakken plm til å utføre en panel-regresjon på dataene. For argumentet index kan dere bruke index = c("NUTS2", "year"). Bruk samme enkle modell som ovenfor dvs. diff_gini_nuts2 ~ diff_gdp_per_capita. Putt resultatet av regresjonen i et objekt p_mod.

Her forsøker vi å unneste NUTS2_diff for at plm() skal finne year.

Her forsøker vi å bruke plm(), men får feilmelding ang. "not subsettable".

Her har vi forsøkt andre metoder, men til ingen hell.

ag_comment: Gode forslag, men problemet var altså plm() som ikke likte list-columns.